

Asignación 4: El Dilema Sesgo-Varianza y Descenso de Gradiente Estocástico

Luis Daniel Gutiérrez Baeza

8 de Junio, 2026

Subtask I: El Dilema Sesgo-Varianza (Bias-Variance Tradeoff)

El error cuadrático medio esperado de cualquier modelo de aprendizaje supervisado puede descomponerse matemáticamente en tres componentes aditivos fundamentales:

$$\mathbb{E}[(y - \hat{f}(x))^2] = \text{Bias}[\hat{f}(x)]^2 + \text{Var}[\hat{f}(x)] + \sigma^2$$

Donde σ^2 representa el ruido irreducible del entorno de datos.

A través de las simulaciones numéricas implementadas con la librería `scikit-learn`, se evaluó el impacto de la complejidad del modelo utilizando ajustes polinomiales sobre funciones senoidales ruidosas:

- **Alto Sesgo (*Underfitting*):** Los modelos lineales simples (grado 1) no poseen la flexibilidad necesaria para capturar la estructura subyacente no lineal, lo que resulta en un error sistemático elevado tanto en el conjunto de entrenamiento como en el de prueba.
- **Alta Varianza (*Overfitting*):** Los modelos altamente complejos (grado 15) memorizan el ruido aleatorio del conjunto de datos. Aunque el error de entrenamiento se aproxima a cero, la varianza es extrema, provocando una pérdida drástica en la capacidad de generalización ante datos nuevos.

Subtask II: Descenso de Gradiente Estocástico (SGD)

El Descenso de Gradiente Estocástico modifica el algoritmo clásico del descenso de gradiente estándar actualizando los pesos y sesgos del modelo utilizando un único ejemplo aleatorio (x_i, y_i) (o un pequeño lote/*minibatch*) en cada iteración, en lugar de calcular el gradiente sobre el dataset completo:

$$\theta_{t+1} = \theta_t - \eta \nabla_{\theta} \mathcal{L}(\theta_t; x_i, y_i)$$

Esta aproximación estocástica introduce fluctuaciones y ruido en la trayectoria de la función de pérdida. Aunque la convergencia no es una línea recta descendente directa, este comportamiento dinámico ruidoso es ventajoso en la optimización de funciones no convexas, ya que le otorga al modelo la capacidad matemática de escapar de mínimos locales subóptimos o puntos de silla para aproximarse eficientemente a mínimos de carácter global.