

Asignación 5: Backpropagation, Arquitecturas Profundas y Modelos Generativos

Luis Daniel Gutiérrez Baeza

8 de Junio, 2026

Subtask II: Backpropagation y Derivación de Componentes

El algoritmo de *Backpropagation* se fundamenta analíticamente en la regla de la cadena del cálculo multivariable. Para una red profunda, el error en la capa de salida $\delta^{(L)}$ utilizando la función de pérdida de entropía cruzada categórica (*categorical cross-entropy*) combinada con una activación Softmax se deriva formalmente como:

$$\delta^{(L)} = \hat{y} - y$$

Donde $\hat{y}$ representa el vector de probabilidades predichas por el modelo e y denota el vector de etiquetas reales codificadas en *one-hot*.

A partir de este componente, el gradiente de la función de pérdida con respecto a la matriz de pesos de la capa $w^{(l)}$ se propaga hacia atrás mediante la relación:

$$\nabla_{w^{(l)}} \mathcal{L} = \delta^{(l)} (a^{(l-1)})^T$$

Donde $a^{(l-1)}$ representa el vector de activaciones de la capa previa. En el caso de la función ReLU ($f(x) = \max(0, x)$), el gradiente cesa su flujo por completo si el argumento de entrada es negativo ($x < 0$), fenómeno matemático conocido formalmente como el problema de las *unidades muertas* o *dead units*.

Subtask III: Análisis de Arquitecturas Complejas (CNN, RNN y Atención)

- **Capas Densas vs. Convolucionales:** Las capas totalmente conectadas (*fully-connected*) poseen una alta cantidad de parámetros computacionales debido a que conectan cada neurona de entrada con cada neurona de salida. En contraste, las capas convolucionales imponen un *sesgo inductivo* de localidad espacial y traslación mediante el desvanecimiento de pesos (*weight sharing*), reduciendo exponencialmente el conteo total de parámetros.

- **Mecanismo de Autoatención (Self-Attention):** El mecanismo transforma la secuencia de entrada en tres matrices conceptuales mediante proyecciones lineales: Queries (Q), Keys (K) y Values (V). La matriz de atención se calcula escalando el producto punto de las consultas y las llaves a través de una función Softmax:

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V$$

Donde $\sqrt{d_k}$ actúa como un factor de normalización matemática para prevenir que los gradientes se desvanezcan en regiones extremas de la función Softmax.

Subtask IV: Modelos Generativos y la Derivación del ELBO

En los Autoencoders Variacionales (VAEs), debido a la imposibilidad de calcular la verosimilitud marginal directa de forma exacta, se maximiza la Cota Inferior de Evidencia o *Evidence Lower Bound* (ELBO). Utilizando la desigualdad de Jensen para funciones cóncavas, se demuestra que el desfase entre la verosimilitud verdadera y el ELBO equivale precisamente a la divergencia KL entre la distribución posterior aproximada $q_\phi(z|x)$ y la distribución posterior verdadera $p_\theta(z|x)$:

$$\ln p_\theta(x) = \text{ELBO}(\phi, \theta; x) + D_{\text{KL}}(q_\phi(z|x) \parallel p_\theta(z|x))$$

Dado que la divergencia KL es estrictamente no negativa ($D_{\text{KL}} \geq 0$), el ELBO constituye una cota inferior válida para la optimización del modelo generativo.